

Modèles de Diffusion Semi-Supervisés avec Incertitude Bayésienne pour la Prédiction Précoce du Sepsis

Proposition de Projet

1. Problème

Le sepsis tue 11 millions de personnes par an [3]. Chaque heure de retard dans le diagnostic augmente la mortalité de 4 à 8%. Les données cliniques en soins intensifs posent trois difficultés majeures : très peu de patients sont labellés « sepsis » ($\sim 2-3\%$), les mesures sont enregistrées à des fréquences irrégulières avec beaucoup de valeurs manquantes et les cliniciens ont besoin d’avoir une valeur d’incertitude du model dans sa prédiction, pas seulement d’une réponse positive ou négative.

2. Idée

Nous adaptons **Diffusion-TS** [1], un modèle génératif de séries temporelles basé sur la diffusion (publié à ICLR 2024), pour en faire un outil de **prédiction du sepsis** qui fonctionne même avec peu de labels et qui quantifie son incertitude.

Diffusion-TS a été conçu pour générer des séries temporelles synthétiques réalistes (testé sur des données financières, énergétiques, physiques). **Il n’a jamais été appliqué à des données cliniques ni à de la classification**, c’est ici que nous apportons notre contribution. Notre approche s’inspire du framework semi-supervisé proposé par Hirnschall [5] pour la détection de fraude bancaire, qui combine GANs, inférence bayésienne et log-signatures, dans lequel nous remplaçons les GANs par un modèle de diffusion plus stable et performant, qui n’est autre que le modèle proposé par [1].

3. Ce qu’on implémente

3.1 Génération conditionnelle pour l’augmentation de données

On utilise le mécanisme de *classifier guidance* de Diffusion-TS [1] pour générer des trajectoires synthétiques de patients *conditionnées par la classe* (sepsis vs non-sepsis). Cela permet de ré-équilibrer le dataset fortement déséquilibré et d’entraîner un classificateur plus robuste en aval.

3.2 Cadre semi-supervisé

On entraîne Diffusion-TS sur **toutes** les données (labellées + non-labellées) pour apprendre la distribution générale des trajectoires de patients. Seul le sous-ensemble labellé est utilisé pour le guidage conditionnel. On teste avec différents ratios de labels : 5%, 10%, 25%, 50%, suivant le protocole de [5].

3.3 Incertitude bayésienne via Monte Carlo Dropout

On ajoute du dropout dans les blocs Transformer du débruiteur. À l’inférence, on fait N passes stochastiques pour obtenir une distribution de prédictions [4]. La variance donne une mesure d’incertitude : si le modèle hésite, le clinicien est alerté.


4. Dataset

PhysioNet/CinC Challenge 2019 [3] (disponible sur Kaggle) :

- +60 000 patients en soins intensifs provenant de trois systèmes hospitaliers
- ~40 variables cliniques par heure (signes vitaux, résultats labo, données démographiques)
- Labels Sepsis-3
- Fort déséquilibre : ~2–3% de cas positifs
- Beaucoup de valeurs manquantes (irrégularité naturelle)

Ce dataset est particulièrement adapté car un modèle basé sur les signatures de chemins a remporté ce challenge [2], validant l'intérêt des approches mathématiques avancées sur ces données.

5. Pipeline technique



6. Métriques d'évaluation

- **AUROC / AUPRC / F1-score** — performance de classification standard
- **Score d'Utilité Clinique PhysioNet** [3] — récompense les prédictions précoces, pénalise les faux positifs
- **ECE** (Expected Calibration Error) — qualité de la calibration de l'incertitude
- **Courbe de report** — précision quand le modèle s'abstient sur ses prédictions les plus incertaines

7. Baselines de comparaison

Méthode	Type
XGBoost / LSTM sur données labellées uniquement	Supervisé classique
Diffusion-TS [1] vanilla + classificateur	Diffusion sans semi-supervisé
TimeGAN semi-supervisé [5]	GAN-based
Diffusion-TS + augmentation + MC Dropout	Notre méthode

8. Outils et ressources

- **Code de base** : <https://github.com/Y-debug-sys/Diffusion-TS> (PyTorch)
- **Dataset** : PhysioNet 2019 via Kaggle (accès libre)
- **GPU** : un seul RTX 3090 suffit (modèle léger, <1h d'entraînement)
- **Librairies** : PyTorch, signatory (log-signatures), scikit-learn

9. Résultats attendus

On s’attend à montrer que :

1. La génération conditionnelle par diffusion améliore la classification par rapport aux baselines supervisées, surtout avec peu de labels (5–10%).
2. Le MC Dropout [4] produit des scores d’incertitude corrélés avec les erreurs du modèle — les cas « incertains » correspondent aux patients cliniquement ambigus.
3. L’approche par diffusion [1] surpasse les approches GAN-based [5] en qualité de génération et en stabilité d’entraînement.

Références

- [1] Yuan, X. & Qiao, Y. (2024). Diffusion-TS : Interpretable Diffusion for General Time Series Generation. *ICLR 2024*.
- [2] Morrill, J. et al. (2020). Utilization of the Signature Method to Identify the Early Onset of Sepsis from Multivariate Physiological Time Series. *Critical Care Medicine*, 48(10).
- [3] Reyna, M.A. et al. (2020). Early Prediction of Sepsis from Clinical Data : The PhysioNet/Computing in Cardiology Challenge 2019. *Critical Care Medicine*.
- [4] Gal, Y. & Ghahramani, Z. (2016). Dropout as a Bayesian Approximation : Representing Model Uncertainty in Deep Learning. *ICML 2016*.
- [5] Hirnschall, D. (2025). Semi-Supervised Bayesian GANs with Log-Signatures for Uncertainty-Aware Credit Card Fraud Detection. *arXiv*.