



ING 3 — CY TECH

Rapport de Projet — *Generative AI*

Modèles de Diffusion Semi-Supervisés avec Incertitude Bayésienne

pour la Prédiction Précoce du Sepsis

Application au PhysioNet/CinC Challenge 2019

Auteurs

Nadir NEILI
Nahil EL BEZZARI
Yassine LAZIZI
Pascal LE
Anis MELAIMI

Encadrant

Arthur SATOUF

9 mai 2026

Table des matières

1	Introduction et Problématique	2
2	Approche Proposée	2
2.1	Génération conditionnelle pour l'augmentation de données	2
2.2	Cadre semi-supervisé	3
2.3	Incertitude bayésienne via Monte Carlo Dropout	3
2.4	Vue d'ensemble du pipeline	3
3	Dataset : PhysioNet/CinC Challenge 2019	4
3.1	Prétraitement	4
4	Architecture des Réseaux	5
4.1	Débruiteur Diffusion-TS	5
4.2	Classifieur Transformer avec MC Dropout	5
5	Résultats Expérimentaux	6
5.1	Paramètres d'entraînement	6
5.2	Comparaison des méthodes	6
5.3	Courbes ROC et Précision-Rappel	7
5.4	Métriques d'incertitude (notre méthode, 10% de labels)	7
5.5	Calibration et distribution de l'incertitude	8
5.6	Ablation : impact du ratio de labels	9
6	Analyse et Discussion	9
6.1	Apport de l'augmentation par diffusion	9
6.2	Comparaison avec les baselines supervisées	9
6.3	Qualité de la calibration et incertitude	9
6.4	Robustesse au ratio de labels	9
6.5	Entraînement et early stopping	10
6.6	Score d'utilité clinique PhysioNet	10
6.7	Limitations	10
7	Conclusion	10

1 Introduction et Problématique

Le sepsis est l’une des principales causes de mortalité en unité de soins intensifs (USI), responsable de 11 millions de décès par an dans le monde [2]. Chaque heure de retard dans le diagnostic augmente la mortalité de 4 à 8 %, ce qui fait de la prédiction précoce un enjeu clinique critique.

Les données cliniques en USI posent trois difficultés majeures qui ont guidé la conception de ce projet :

1. **Très peu de patients labellés** : environ 2–3 % des patients développent un sepsis (Sepsis-3), rendant l’apprentissage supervisé classique peu efficace.
2. **Mesures irrégulières et valeurs manquantes** : les variables cliniques (signes vitaux, résultats de laboratoire) sont enregistrées à des fréquences variables et présentent de nombreuses valeurs manquantes.
3. **Besoin de quantification de l’incertitude** : un clinicien a besoin de savoir *à quel point* le modèle est sûr de sa prédiction, pas seulement d’un verdict binaire.

Ce rapport présente l’adaptation de **Diffusion-TS** [1], un modèle génératif de séries temporelles publié à ICLR 2024, dans un cadre semi-supervisé avec quantification de l’incertitude bayésienne par Monte Carlo Dropout [3].

Contributions principales. Ce projet apporte trois contributions complémentaires :

1. **Adaptation de Diffusion-TS au domaine clinique** : transposition d’un modèle DDPM conçu pour des séries temporelles génériques aux trajectoires multivariées d’unités de soins intensifs (40 variables, 24 h glissantes, fortes valeurs manquantes).
2. **Génération conditionnelle semi-supervisée** : entraînement du modèle de diffusion sur *l’ensemble* du dataset (labellé + non labellé) avec *classifier-free guidance*, pour produire des trajectoires synthétiques de sepsis qui rééquilibrent un classifieur Transformer.
3. **Quantification de l’incertitude par MC Dropout** : production d’un score d’incertitude par échantillon, dont la corrélation avec l’erreur (variance $\times 6.6$ plus élevée sur les prédictions incorrectes) permet une stratégie d’abstention clinique.

Sur le jeu de test (10 % de labels), notre méthode atteint AUROC = 0.868, AUPRC = 0.136 et un score d’utilité PhysioNet de -0.080 , surpassant cinq baselines (XGBoost, BiLSTM, Transformer sans augmentation, TimeGAN, Path Signatures).

2 Approche Proposée

L’objectif final est un **classifieur** de sepsis robuste malgré le faible nombre de patients labellés. Pour y parvenir, nous chaînons deux modèles distincts : un modèle de diffusion qui *génère* des trajectoires patients synthétiques étiquetées sepsis, suivi d’un classifieur Transformer qui *prédit* le sepsis sur les données réelles augmentées par ces synthétiques. Cette séparation permet à la diffusion d’exploiter la totalité du dataset (labellé + non labellé) pour apprendre la structure des trajectoires, là où un classifieur supervisé classique se limiterait aux 10 % labellés.

Notre approche repose sur trois composantes distinctes et complémentaires.

2.1 Génération conditionnelle pour l’augmentation de données

Principe d’un modèle de diffusion (DDPM). Un modèle DDPM apprend à *inverser* un processus qui dégrade progressivement une donnée réelle x_0 en bruit gaussien $x_T \sim \mathcal{N}(0, I)$ sur T pas. Pendant l’entraînement, le réseau apprend à prédire le bruit ajouté à chaque étape ; à l’inférence, on part de bruit pur et on déroule le processus inverse pour synthétiser une

donnée propre. Diffusion-TS [1] adapte ce paradigme aux séries temporelles via un débruiteur Transformer dont la sortie est explicitement décomposée en une composante *tendance* (lente) et une composante *saisonnalité* (rapide), ce qui aide à capturer la structure clinique des trajectoires.

Schedule de bruit cosinus [4]. Le rythme auquel le bruit est ajouté est défini par le coefficient $\bar{\alpha}_t$; le schedule cosinus ajoute le bruit plus lentement au début et à la fin du processus, ce qui stabilise l'entraînement sur des séries courtes (24 pas de temps).

$$\bar{\alpha}_t = \frac{f(t)}{f(0)}, \quad f(t) = \cos\left(\frac{t/T + s}{1 + s} \cdot \frac{\pi}{2}\right)^2, \quad s = 0.008$$

Classifier-free guidance (CFG). Pour générer des trajectoires d'une classe *spécifique* (sepsis), on entraîne le même réseau à connaître à la fois la distribution générale (sans label, $\emptyset$) et la distribution conditionnelle (avec label c). À l'échantillonnage, on combine les deux prédictions de bruit avec un coefficient γ qui contrôle le degré de conformité à la classe : $\gamma = 1$ correspond à l'échantillonnage purement conditionnel, $\gamma > 1$ accentue l'effet de la classe au prix de la diversité.

$$\hat{\epsilon} = \epsilon_\theta(x_t, t, \emptyset) + \gamma[\epsilon_\theta(x_t, t, c) - \epsilon_\theta(x_t, t, \emptyset)], \quad \gamma = 1.5$$

2.2 Cadre semi-supervisé

Le modèle de diffusion est entraîné sur **toutes** les données (labellées et non labellées) pour apprendre la distribution générale des trajectoires patients. Le guidage conditionnel n'utilise que le sous-ensemble labellé (10 % des positifs dans notre configuration principale, soit 215 patients sur 2 157).

2.3 Incertitude bayésienne via Monte Carlo Dropout

L'idée de [3] est que conserver le *Dropout actif à l'inférence* revient à échantillonner différentes sous-architectures du réseau, ce qui approxime une distribution postérieure bayésienne sur les poids. En moyennant N passes stochastiques, on obtient une estimation plus stable de la probabilité ; en mesurant leur variance, on obtient un score d'incertitude par échantillon. Concrètement, des couches Dropout ($p = 0.2$) sont maintenues actives à l'évaluation, et $N = 50$ passes produisent :

$$p^*(y = 1 | x) = \frac{1}{N} \sum_{n=1}^N \sigma(f_{\hat{\theta}_n}(x)), \quad \text{Unc}(x) = \text{Var}_n[\sigma(f_{\hat{\theta}_n}(x))]$$

2.4 Vue d'ensemble du pipeline

La figure 1 synthétise les trois composantes : Diffusion-TS apprend sur l'intégralité du dataset, génère des trajectoires synthétiques de sepsis qui rééquilibrent l'entraînement du classifieur, lequel produit *in fine* la prédiction et son score d'incertitude.




FIGURE 1 – Pipeline complet du système de prédiction du sepsis.

3 Dataset : PhysioNet/CinC Challenge 2019

TABLE 1 – Caractéristiques du dataset PhysioNet/CinC Challenge 2019 [2]

Caractéristique	Valeur
Nombre total de patients	40 336
Variables cliniques	40 (8 signes vitaux, 26 résultats labo, 6 démographiques)
Label	Sepsis-3
Déséquilibre de classes	≈ 2.29 % de cas positifs
Valeurs manquantes	Importantes (mesures à fréquence irrégulière)
Provenance	2 systèmes hospitaliers (set A et set B)

3.1 Prétraitement

1. **Imputation** : forward fill, backward fill, puis zéro. Masque binaire d'observation conservé comme variable auxiliaire.
2. **Fenêtrage glissant** : fenêtres de 24 h, pas de 6 h. Label positif si SepsisLabel = 1 sur au moins un pas de temps.
3. **Split patient-level** : train/val/test (75/10/15 %) au niveau du patient pour éviter toute fuite de données.
4. **Normalisation** : StandardScaler ajusté sur le train uniquement.

TABLE 2 – Répartition des fenêtres après prétraitement

Split	Fenêtres	Positifs	Taux positif
Train	94 341	2 157	2.29 %
Val	12 840	316	2.46 %
Test	18 807	410	2.18 %
Total	125 988	2 883	2.29 %

4 Architecture des Réseaux

4.1 Débruiteur Diffusion-TS

- **Embedding temporel** : encodage sinusoïdal de t + embedding de classe c .
- **Décomposition tendance/saisonnalité** : moyenne mobile causale (noyau 5).
- **Backbone** : 4 blocs Transformer ($d_{\text{model}} = 128$, 8 têtes, $d_{ff} = 256$, Dropout $p = 0.1$).
- **Sortie** : deux branches parallèles (tendance + saisonnalité) recombinaées.

4.2 Classifieur Transformer avec MC Dropout

- **Entrée** : $[x \parallel m] \in \mathbb{R}^{B \times T \times 2F}$ (features + masque).
- **Token [CLS]** : token appris prépendu à la séquence.
- **Backbone** : 3 blocs Transformer ($d_{\text{model}} = 128$, 8 têtes, Dropout $p = 0.2$).
- **Tête** : MLP $128 \rightarrow 64 \rightarrow 1$.
- **Seuil** : indice de Youden calibré sur le jeu de validation.

5 Résultats Expérimentaux

5.1 Paramètres d'entraînement

TABLE 3 – Hyperparamètres principaux


Paramètre	Valeur
<i>Modèle de diffusion</i>	
Pas de diffusion T	1 000
Schedule	Cosinus
d_{model} / têtes / couches	128 / 8 / 4
Epochs	100 (loss finale = 0.085)
Batch size / lr	64 / 2×10^{-4}
<i>Classifieur</i>	
d_{model} / têtes / couches	128 / 8 / 3
Dropout MC	0.2
Passes MC à l'inférence	50
Meilleure epoch (early stopping)	8 / 50 (patience = 10)
Batch size / lr	64 / 10^{-4}
<i>Semi-supervisé</i>	
Ratio de labels (positifs)	10 % (215 / 2 157)
Oversampling synthétique	$\times 3 \Rightarrow 6\,471$ fenêtres
Guidance scale γ	1.5

5.2 Comparaison des méthodes

TABLE 4 – Résultats sur le jeu de test (10% de labels positifs). Seuil calibré par l'indice de Youden sur la validation. $\uparrow$ meilleur, $\downarrow$ meilleur. $\dagger$: signatures sur 8 signes vitaux, depth=2, semi-supervisé (10% labels) — conditions différentes de Morrill et al. ; ECE/Util non disponibles pour ce run.

Méthode	AUROC $\uparrow$	AUPRC $\uparrow$	F1 $\uparrow$	Util. $\uparrow$	ECE $\downarrow$
XGBoost (labellé seul.)	0.7835	0.0997	0.1156	−0.468	0.020
BiLSTM (labellé seul.)	0.8410	0.1086	0.1252	−0.165	0.029
Transformer (sans augm.)	0.7892	0.0801	0.1092	−0.472	0.016
TimeGAN semi-sup. (Yoon et al.)	0.8363	0.0993	0.1269	−0.229	0.014
Path Signatures + XGBoost $\dagger$ (Morrill et al.)	0.7962	0.1009	0.1085	—	—
Diffusion-TS + Aug + MC Dropout (ours)	0.8679	0.1363	0.1139	−0.080	0.009

5.3 Courbes ROC et Précision-Rappel



(a) Courbe ROC (AUROC = 0.8679)

(b) Courbe Précision-Rappel (AUPRC = 0.1363)

FIGURE 2 – Performance de classification sur le jeu de test (18 807 fenêtres, 2.18% positifs, seuil optimal = 0.018 calibré par l'indice de Youden sur la validation). La courbe PR est la métrique principale pour les données fortement déséquilibrées.

5.4 Métriques d'incertitude (notre méthode, 10% de labels)

TABLE 5 – Métriques d'incertitude bayésienne sur le jeu de test (ratio de labels = 10%)

Métrique	Valeur
ECE (Expected Calibration Error)	0.0088
Brier score	0.0203
Score d'utilité PhysioNet	−0.080
Corrélation incertitude-erreur	0.258
Variance MC — prédictions correctes	2.12×10^{-4}
Variance MC — prédictions incorrectes	1.39×10^{-3}
Seuil optimal (Youden, val set)	0.0178

5.5 Calibration et distribution de l'incertitude




FIGURE 3 – Qualité de calibration et corrélation incertitude–erreur. **Gauche** : le modèle est bien calibré (la courbe orange suit la diagonale), et les probabilités prédites pour les cas sepsis se concentrent au-dessus de 0.1, distinctes des non-sepsis (<0.05). **Droite** : la variance MC Dropout des prédictions incorrectes est $6.6\times$ supérieure à celle des prédictions correctes, validant l'utilité clinique du score d'incertitude.




FIGURE 4 – Courbe d'abstention : précision en fonction de la fraction d'échantillons conservés (les plus incertains sont écartés en premier). À 50% de couverture (le modèle s'abstient sur la moitié la plus incertaine), la précision sur les alertes conservées est significativement supérieure à la précision de base (2.2%).

5.6 Ablation : impact du ratio de labels

TABLE 6 – Performance en fonction du ratio de labels positifs utilisés pour le guidage conditionnel. Le modèle de diffusion est ré-entraîné à chaque ratio.

Ratio	Labels (+)	AUROC↑	AUPRC↑	F1↑	ECE↓
5%	108	0.8642	0.1443	0.1410	0.0170
10%	215	0.8679	0.1363	0.1139	0.0088
25%	539	0.8669	0.1484	0.1153	0.0179
50%	1078	0.8684	0.1356	0.1228	0.0058

6 Analyse et Discussion

6.1 Apport de l’augmentation par diffusion

La comparaison entre le Transformer vanilla (AUROC = 0.789) et notre méthode (AUROC = 0.868) révèle un gain de **+7.9 points d’AUROC** dû exclusivement à l’augmentation par génération conditionnelle. Ce résultat démontre que Diffusion-TS produit des trajectoires patients synthétiques suffisamment réalistes pour entraîner un classifieur robuste avec seulement 215 exemples positifs labellés.

6.2 Comparaison avec les baselines supervisées

Notre méthode surpasse le BiLSTM de **+2.7 pts AUROC** et de **+25.5 % relatif en AUPRC** (0.1363 vs 0.1086). L’AUPRC est la métrique la plus pertinente pour les datasets déséquilibrés car elle est insensible à l’abondance de vrais négatifs. Le score d’utilité PhysioNet est le plus discriminant : -0.080 pour notre méthode contre -0.165 pour le BiLSTM ($2\times$ meilleur), traduisant un meilleur compromis sensibilité/spécificité au seuil opérationnel.

Le F1 du BiLSTM (0.1252) est légèrement supérieur au nôtre (0.1139) : un modèle entraîné sur données synthétiques a une frontière de décision plus diffuse, ce qui pénalise marginalement le F1 à seuil fixe.

6.3 Qualité de la calibration et incertitude

L’ECE de **0.009** indique une très bonne calibration, propriété essentielle en milieu clinique. La corrélation incertitude–erreur de **0.258** confirme l’utilité du MC Dropout : la variance sur les prédictions incorrectes est **6.6 fois plus élevée** que sur les correctes (1.39×10^{-3} vs 2.12×10^{-4}).

6.4 Robustesse au ratio de labels

Le résultat le plus frappant de l’ablation est la **stabilité remarquable de l’AUROC** à travers tous les ratios : la variation totale n’est que de 0.004 points (0.8642 à 0.8684). Cela s’explique par l’architecture semi-supervisée : le modèle de diffusion apprend la distribution générale des trajectoires patients sur *toutes* les données sans supervision, et le guidage conditionnel ne sert qu’à orienter la génération synthétique. Avec seulement **108 exemples positifs labellés (5%)**, le système atteint déjà AUROC = 0.864.

L’AUPRC culmine à 25% (0.1484), suggérant que le rapport signal/bruit dans les données synthétiques générées est optimal à ce ratio. En dessous (5–10%), les synthétiques sont moins fidèles faute de supervision ; au-dessus (50%), le surplus de labels n’apporte pas de gain car la distribution est déjà bien capturée.

L'ECE est minimale à 50% (0.0058) — la configuration la mieux calibrée — tandis qu'à 25% on observe le plus mauvais ECE (0.0179) malgré la meilleure AUPRC. La calibration bayésienne du MC Dropout n'évolue donc pas de façon monotone avec le ratio de labels, mais reste partout inférieure à 0.02, ce qui demeure cliniquement acceptable.

6.5 Entraînement et early stopping

L'évolution de l'AUROC de validation a révélé un sur-apprentissage dès l'époch 9 (AUROC = 0.8521 à l'époch 8, puis déclin vers 0.760 à l'époch 50). L'early stopping avec patience = 10 a permis de sauvegarder le meilleur modèle automatiquement. Ce comportement s'explique par la présence de données synthétiques dans le jeu d'entraînement augmenté : le modèle finit par mémoriser leurs patterns plutôt que les patterns cliniques réels.

6.6 Score d'utilité clinique PhysioNet

Le score de -0.080 est très proche de zéro (vs -1.97 avec seuil par défaut de 0.5). Le seuil optimal de 0.0178 reflète le déséquilibre asymétrique de la fonction de coût clinique : pénalité FN = -2.0 , pénalité FP = -0.05 .

6.7 Limitations

1. **AUPRC modeste (0.136)** : les meilleures solutions du challenge PhysioNet 2019 atteignaient 0.3–0.5 avec accès à l'intégralité des labels.
2. **Diffusion sous-entraînée** : 100 epochs suffisent pour faire converger la loss mais pas pour générer des échantillons optimaux. Un entraînement à 200+ epochs améliorerait la qualité des synthétiques.
3. **Score d'utilité simplifié** : nous utilisons une approximation du score PhysioNet 2019 (TP/FP/FN/TN constants par fenêtre) au lieu de la version officielle par-patient avec décroissance temporelle (`dt_early`, `dt_optimal`, `dt_late`). Les valeurs absolues ne sont donc pas directement comparables aux scores du challenge ; les comparaisons inter-méthodes au sein de ce rapport restent cohérentes car toutes utilisent la même formule.

7 Conclusion

Ce projet démontre la faisabilité de l'adaptation de Diffusion-TS à la prédiction précoce du sepsis dans un cadre semi-supervisé avec incertitude bayésienne. Les trois contributions sont validées expérimentalement :

1. **L'augmentation par diffusion améliore significativement la classification** (+7.9 pts AUROC vs Transformer vanilla, +2.7 pts vs BiLSTM supervisé).
2. **Le MC Dropout produit des scores d'incertitude utiles** : variance $6.6 \times$ plus élevée sur les erreurs, ECE = 0.009.
3. **La diffusion surpasse les GAN-based** en stabilité d'entraînement, sans effondrement de mode ni oscillation de la loss.

Code source, tests (76 tests, 100 % de réussite) et instructions de reproduction : <https://github.com/BigYellowData/diffusion-ts-sepsis>

Références

- [1] Yuan, X. & Qiao, Y. (2024). *Diffusion-TS : Interpretable Diffusion for General Time Series Generation*. ICLR 2024.
- [2] Reyna, M.A. et al. (2020). *Early Prediction of Sepsis from Clinical Data : The PhysioNet/Computing in Cardiology Challenge 2019*. Critical Care Medicine.
- [3] Gal, Y. & Ghahramani, Z. (2016). *Dropout as a Bayesian Approximation : Representing Model Uncertainty in Deep Learning*. ICML 2016.
- [4] Nichol, A. & Dhariwal, P. (2021). *Improved Denoising Diffusion Probabilistic Models*. ICML 2021.
- [5] Hirnschall, D. (2025). *Semi-Supervised Bayesian GANs with Log-Signatures for Uncertainty-Aware Credit Card Fraud Detection*. arXiv.
- [6] Morrill, J. et al. (2020). *Utilization of the Signature Method to Identify the Early Onset of Sepsis from Multivariate Physiological Time Series*. Critical Care Medicine, 48(10).