



ING 3 — CY TECH

Rapport de Projet — *Generative AI*

Modèles de Diffusion Semi-Supervisés avec Incertitude Bayésienne

pour la Prédiction Précoce du Sepsis

Application au PhysioNet/CinC Challenge 2019

Auteurs

Nadir NEILI
Nahil EL BEZZARI
Yassine LAZIZI
Pascal LE
Anis MELAIMI

Encadrant

Arthur SATOUF

9 mai 2026

Table des matières

1	Introduction et Problématique	2
2	Approche Proposée	2
2.1	Génération conditionnelle pour l'augmentation de données	3
2.2	Cadre semi-supervisé	3
2.3	Incertitude bayésienne via Monte Carlo Dropout	3
2.4	Vue d'ensemble du pipeline	4
3	Dataset : PhysioNet/CinC Challenge 2019	4
3.1	Prétraitement	4
4	Architecture des Réseaux	5
4.1	Débruiteur Diffusion-TS	5
4.2	Classifieur Transformer avec MC Dropout	5
5	Résultats Expérimentaux	6
5.1	Paramètres d'entraînement	6
5.2	Comparaison des méthodes	6
5.3	Courbes ROC et Précision-Rappel	7
5.4	Métriques d'incertitude (notre méthode, 10% de labels)	7
5.5	Calibration et distribution de l'incertitude	8
5.6	Visualisation des trajectoires synthétiques	8
5.7	Exemples qualitatifs (4 cas du test set)	9
5.8	Ablation : impact du ratio de labels	10
6	Analyse et Discussion	10
6.1	Apport de l'augmentation par diffusion	10
6.2	Comparaison avec les baselines supervisées	10
6.3	Qualité de la calibration et incertitude	10
6.4	Robustesse au ratio de labels	10
6.5	Entraînement et early stopping	11
6.6	Score d'utilité clinique PhysioNet	11
6.7	Limitations	11
7	Conclusion	11

1 Introduction et Problématique

Le sepsis est l'une des principales causes de mortalité en unité de soins intensifs (USI), responsable de 11 millions de décès par an dans le monde [2]. Chaque heure de retard dans le diagnostic augmente la mortalité de 4 à 8 %, ce qui fait de la prédiction précoce un enjeu clinique critique.

Les données cliniques en USI posent trois difficultés majeures qui ont guidé la conception de ce projet :

1. **Très peu de patients labellés** : environ 2–3 % des patients développent un sepsis (Sepsis-3), rendant l'apprentissage supervisé classique peu efficace.
2. **Mesures irrégulières et valeurs manquantes** : les variables cliniques (signes vitaux, résultats de laboratoire) sont enregistrées à des fréquences variables et présentent de nombreuses valeurs manquantes.
3. **Besoin de quantification de l'incertitude** : un clinicien a besoin de savoir *à quel point* le modèle est sûr de sa prédiction, pas seulement d'un verdict binaire.

Ce rapport présente l'adaptation de **Diffusion-TS** [1], un modèle génératif de séries temporelles publié à ICLR 2024, dans un cadre semi-supervisé avec quantification de l'incertitude bayésienne par Monte Carlo Dropout [3].

Contributions principales. Ce projet apporte trois contributions complémentaires :

1. **Première application de Diffusion-TS à des données cliniques et à une tâche de classification** : ce modèle, conçu initialement pour la génération de séries temporelles génériques (financières, énergétiques, physiques), n'a jamais été appliqué à un problème clinique ni à de la classification. Nous le transposons aux trajectoires multivariées d'unités de soins intensifs (40 variables, 24 h glissantes, fortes valeurs manquantes).
2. **Génération conditionnelle semi-supervisée** : entraînement du modèle de diffusion sur *l'ensemble* du dataset (labellé + non labellé) avec *classifier-free guidance*, pour produire des trajectoires synthétiques de sepsis qui rééquilibrent un classifieur Transformer.
3. **Quantification de l'incertitude par MC Dropout** : production d'un score d'incertitude par échantillon, dont la corrélation avec l'erreur (variance $\times 12.8$ plus élevée sur les prédictions incorrectes, Pearson $r = 0.43$) permet d'identifier en aval les cas où le modèle hésite et qui nécessitent une vérification humaine.

Sur le jeu de test (10 % de labels), notre méthode atteint AUROC = 0.868, AUPRC = 0.136 et un score d'utilité PhysioNet de -0.080 , surpassant cinq baselines (XGBoost, BiLSTM, Transformer sans augmentation, TimeGAN, Path Signatures).

2 Approche Proposée

L'objectif final est un **classifieur** de sepsis robuste malgré le faible nombre de patients labellés. Pour y parvenir, nous chaînons deux modèles distincts : un modèle de diffusion qui *génère* des trajectoires patients synthétiques étiquetées sepsis, suivi d'un classifieur Transformer qui *prédit* le sepsis sur les données réelles augmentées par ces synthétiques. Cette séparation permet à la diffusion d'exploiter la totalité du dataset (labellé + non labellé) pour apprendre la structure des trajectoires patients, là où un classifieur supervisé classique ne peut tirer aucune information des 1 942 fenêtres positives dont l'étiquette est cachée (90 % des positifs).

Cette approche s'inspire conceptuellement du travail de Hirnschall [5], qui applique un cadre similaire — modèle génératif semi-supervisé augmenté d'une quantification d'incertitude bayésienne — au problème déséquilibré de la détection de fraude bancaire, avec des GANs sur log-signatures. Notre contribution principale est de **transposer cette méthodologie** aux

trajectoires cliniques en remplaçant le générateur GAN par un modèle de diffusion (Diffusion-TS [1]), plus stable à l’entraînement et capable d’apprendre la distribution générale des données non labellées sans effondrement de mode.

Notre approche repose sur trois composantes distinctes et complémentaires.

2.1 Génération conditionnelle pour l’augmentation de données

Principe d’un modèle de diffusion (DDPM). Un modèle DDPM apprend à *inverser* un processus qui dégrade progressivement une donnée réelle x_0 en bruit gaussien $x_T \sim \mathcal{N}(0, I)$ sur T pas. Pendant l’entraînement, le réseau apprend à prédire le bruit ajouté à chaque étape ; à l’inférence, on part de bruit pur et on déroule le processus inverse pour synthétiser une donnée propre. Diffusion-TS [1] adapte ce paradigme aux séries temporelles via un débruiteur Transformer dont la sortie est explicitement décomposée en une composante *tendance* (lente) et une composante *saisonnalité* (rapide), ce qui aide à capturer la structure clinique des trajectoires.

Schedule de bruit cosinus [4]. Le rythme auquel le bruit est ajouté est défini par le coefficient $\bar{\alpha}_t$; le schedule cosinus ajoute le bruit plus lentement au début et à la fin du processus, ce qui stabilise l’entraînement sur des séries courtes (24 pas de temps).

$$\bar{\alpha}_t = \frac{f(t)}{f(0)}, \quad f(t) = \cos\left(\frac{t/T + s}{1 + s} \cdot \frac{\pi}{2}\right)^2, \quad s = 0.008$$

Classifier-free guidance (CFG). Pour générer des trajectoires d’une classe *spécifique* (sepsis), on entraîne le même réseau à connaître à la fois la distribution générale (sans label, $\emptyset$) et la distribution conditionnelle (avec label c). À l’échantillonnage, on combine les deux prédictions de bruit avec un coefficient γ qui contrôle le degré de conformité à la classe : $\gamma = 1$ correspond à l’échantillonnage purement conditionnel, $\gamma > 1$ accentue l’effet de la classe au prix de la diversité.

$$\hat{\epsilon} = \epsilon_\theta(x_t, t, \emptyset) + \gamma[\epsilon_\theta(x_t, t, c) - \epsilon_\theta(x_t, t, \emptyset)], \quad \gamma = 1.5$$

2.2 Cadre semi-supervisé

Le modèle de diffusion est entraîné sur **toutes** les données (labellées et non labellées) pour apprendre la distribution générale des trajectoires patients. Le guidage conditionnel n’utilise que le sous-ensemble labellé (10 % des positifs dans notre configuration principale, soit 215 *fenêtres positives* sur 2 157 — issues d’environ 80–100 patients distincts, un patient septique générant typiquement 2 à 3 fenêtres positives via le fenêtrage glissant).

2.3 Incertitude bayésienne via Monte Carlo Dropout

L’idée de [3] est que conserver le *Dropout actif* à l’inférence revient à échantillonner différentes sous-architectures du réseau, ce qui approxime une distribution postérieure bayésienne sur les poids. En moyennant N passes stochastiques, on obtient une estimation plus stable de la probabilité ; en mesurant leur variance, on obtient un score d’incertitude par échantillon. Concrètement, des couches Dropout ($p = 0.2$) sont maintenues actives à l’évaluation, et $N = 50$ passes produisent :

$$p^*(y = 1 | x) = \frac{1}{N} \sum_{n=1}^N \sigma(f_{\hat{\theta}_n}(x)), \quad \text{Unc}(x) = \text{Var}_n[\sigma(f_{\hat{\theta}_n}(x))]$$

2.4 Vue d'ensemble du pipeline

La figure 1 synthétise les trois composantes : Diffusion-TS apprend sur l'intégralité du dataset, génère des trajectoires synthétiques de sepsis qui rééquilibrent l'entraînement du classifieur, lequel produit *in fine* la prédiction et son score d'incertitude.




FIGURE 1 – Pipeline complet du système de prédiction du sepsis.

3 Dataset : PhysioNet/CinC Challenge 2019

TABLE 1 – Caractéristiques du dataset PhysioNet/CinC Challenge 2019 [2]

Caractéristique	Valeur
Nombre total de patients	40 336
Variables cliniques	40 (8 signes vitaux, 26 résultats labo, 6 démographiques)
Label	Sepsis-3
Déséquilibre de classes	≈ 2.29 % de cas positifs
Valeurs manquantes	Importantes (mesures à fréquence irrégulière)
Provenance	2 systèmes hospitaliers (set A et set B)

3.1 Prétraitement

1. **Imputation** : forward fill, backward fill, puis zéro. Masque binaire d'observation conservé comme variable auxiliaire.
2. **Fenêtrage glissant** : fenêtres de 24 h, pas de 6 h. Label positif si SepsisLabel = 1 sur au moins un pas de temps.

3. **Split patient-level** : train/val/test (75/10/15 %) au niveau du patient pour éviter toute fuite de données.
4. **Normalisation** : StandardScaler ajusté sur le train uniquement.

TABLE 2 – Répartition des fenêtres après prétraitement

Split	Fenêtres	Positifs	Taux positif
Train	94 341	2 157	2.29 %
Val	12 840	316	2.46 %
Test	18 807	410	2.18 %
Total	125 988	2 883	2.29 %

4 Architecture des Réseaux

4.1 Débruiteur Diffusion-TS

- **Embedding temporel** : encodage sinusoïdal de t + embedding de classe c .
- **Décomposition tendance/saisonnalité** : moyenne mobile causale (noyau 5).
- **Backbone** : 4 blocs Transformer ($d_{\text{model}} = 128$, 8 têtes, $d_{ff} = 256$, Dropout $p = 0.1$).
- **Sortie** : deux branches parallèles (tendance + saisonnalité) recombinaées.

4.2 Classifieur Transformer avec MC Dropout

- **Entrée** : $[x \parallel m] \in \mathbb{R}^{B \times T \times 2F}$ (features + masque).
- **Token [CLS]** : token appris prépendu à la séquence.
- **Backbone** : 3 blocs Transformer ($d_{\text{model}} = 128$, 8 têtes, Dropout $p = 0.2$).
- **Tête** : MLP $128 \rightarrow 64 \rightarrow 1$.
- **Seuil** : indice de Youden calibré sur le jeu de validation.

5 Résultats Expérimentaux

5.1 Paramètres d'entraînement

TABLE 3 – Hyperparamètres principaux


Paramètre	Valeur
<i>Modèle de diffusion</i>	
Pas de diffusion T	1 000
Schedule	Cosinus
d_{model} / têtes / couches	128 / 8 / 4
Epochs	100 (loss finale = 0.085)
Batch size / lr	64 / 2×10^{-4}
<i>Classifieur</i>	
d_{model} / têtes / couches	128 / 8 / 3
Dropout MC	0.2
Passes MC à l'inférence	50
Meilleure epoch (early stopping)	8 / 50 (patience = 10)
Batch size / lr	64 / 10^{-4}
<i>Semi-supervisé</i>	
Ratio de labels (positifs)	10 % (215 / 2 157)
Oversampling synthétique	$\times 3 \Rightarrow 6\,471$ fenêtres
Guidance scale γ	1.5
Distribution post-augmentation	6 686 sepsis / 92 184 sains (6.77 % / 93.23 %)
Total fenêtres train (classifieur)	98 870

5.2 Comparaison des méthodes

TABLE 4 – Résultats sur le jeu de test (10% de labels positifs). Seuil calibré par l'indice de Youden sur la validation. $\uparrow$ meilleur, $\downarrow$ meilleur. $\dagger$: signatures sur 8 signes vitaux, depth=2, semi-supervisé (10% labels) — conditions différentes de Morrill et al. ; ECE/Util non disponibles pour ce run.

Méthode	AUROC $\uparrow$	AUPRC $\uparrow$	F1 $\uparrow$	Util. $\uparrow$	ECE $\downarrow$
XGBoost (labellé seul.)	0.7835	0.0997	0.1156	−0.468	0.020
BiLSTM (labellé seul.)	0.8410	0.1086	0.1252	−0.165	0.029
Transformer (sans augm.)	0.7892	0.0801	0.1092	−0.472	0.016
TimeGAN semi-sup. [7]	0.8363	0.0993	0.1269	−0.229	0.014
Path Signatures + XGBoost $\dagger$ [6]	0.7962	0.1009	0.1085	—	—
Diffusion-TS + Aug + MC Dropout (ours)	0.8679	0.1363	0.1139	−0.080	0.009

5.3 Courbes ROC et Précision-Rappel



(a) Courbe ROC (AUROC = 0.8679)

(b) Courbe Précision-Rappel (AUPRC = 0.1363)

FIGURE 2 – Performance de classification sur le jeu de test (18 807 fenêtres, 2.18% positifs, seuil optimal = 0.018 calibré par l'indice de Youden sur la validation). La courbe PR est la métrique principale pour les données fortement déséquilibrées.

5.4 Métriques d'incertitude (notre méthode, 10% de labels)

TABLE 5 – Métriques d'incertitude bayésienne sur le jeu de test (ratio de labels = 10%)

Métrique	Valeur
ECE (Expected Calibration Error)	0.0088
Brier score	0.0203
Score d'utilité PhysioNet	−0.080
Corrélation incertitude-erreur	0.426
Variance MC — prédictions correctes	5.34×10^{-5}
Variance MC — prédictions incorrectes	6.85×10^{-4}
Seuil optimal (Youden, val set)	0.0178

5.5 Calibration et distribution de l'incertitude




FIGURE 3 – Qualité de calibration et corrélation incertitude-erreur. **Gauche** : le modèle est bien calibré (la courbe orange suit la diagonale). La distribution des probabilités prédites pour les cas sepsis présente une queue qui s'étend jusqu'à 0.4, contrairement aux non-sepsis qui restent fortement concentrés sous 0.05. **Droite** : la variance MC Dropout des prédictions incorrectes est $12.8\times$ supérieure à celle des prédictions correctes, validant l'utilité du score d'incertitude pour identifier les cas où le modèle hésite.

5.6 Visualisation des trajectoires synthétiques

Avant d'attribuer le gain de performance à la qualité des échantillons générés, il convient de vérifier visuellement que les trajectoires synthétiques produites par Diffusion-TS sont cliniquement plausibles. La figure 4 compare six vraies trajectoires de sepsis (extraites du jeu d'entraînement) à six échantillons générés par notre modèle avec guidage conditionnel $c = 1$ et $\gamma = 1.5$, sur cinq signes vitaux clés.




FIGURE 4 – Trajectoires sur 24h de signes vitaux. **Haut (bleu)** : 6 patients réels avec sepsis. **Bas (orange)** : 6 fenêtres synthétiques générées par Diffusion-TS conditionné sur $c = 1$ (DDIM, 50 pas, $\gamma = 1.5$).

Les échantillons synthétiques reproduisent les grandes plages physiologiques attendues (HR

50–130, Temp 35–41, MAP 50–130, etc.) ainsi que les variations lentes d’amplitude réaliste (pas de discontinuités, pas de plateaux artificiels). Les amplitudes sont parfois légèrement plus larges que sur les vrais patients, reflet du coefficient de guidance $\gamma = 1.5$ qui accentue le caractère “pathologique” au détriment de la diversité fine.




FIGURE 5 – Distributions marginales des signes vitaux : valeurs réelles (sepsis, $n \approx 2\,157$ fenêtres $\times$ 24 pas) vs valeurs générées (200 fenêtres synthétiques $\times$ 24 pas). Les distributions se recouvrent largement, validant que les trajectoires synthétiques sont statistiquement proches des vraies — condition nécessaire à un gain en classification.

Cette validation visuelle est essentielle : un gain de classification dû à des échantillons aberrants ou trop éloignés de la distribution réelle ne généraliserait pas. Ici le recouvrement des distributions confirme que la diffusion apprend la bonne variété de données.

5.7 Exemples qualitatifs (4 cas du test set)

Pour illustrer concrètement la sortie du modèle, nous présentons quatre cas représentatifs extraits du jeu de test, chacun choisi pour mettre en lumière un comportement particulier (vrai positif confiant, vrai négatif confiant, faux positif incertain, faux négatif silencieux). La table 6 résume les plages observées des principaux signes vitaux sur la fenêtre 24h et la sortie du classifieur.

TABLE 6 – Quatre cas extraits du test set (10% de labels). Plages des signes vitaux observés sur la fenêtre 24h, probabilité prédite par le modèle (moyenne sur 50 passes MC Dropout), variance associée, et décision binaire au seuil de Youden 0.018. Les unités : HR en battements/min, MAP et SBP en mmHg, Temp en $^{\circ}\text{C}$, Lactate en mmol/L.

Cas	HR	Temp	MAP	Lactate	y_{vrai}	$P(\text{sepsis})$	Var MC ($\times 10^{-3}$)	Décision
TP confiant	79–100	37.1–38.0	67–109	non mesuré	sepsis	0.419	1.07	SEPSIS ✓
TN confiant	52–100	36.1–36.7	73–96	non mesuré	sain	0.002	0.001	non-sepsis ✓
FP incertain	86–135	36.6–37.7	92→69	non mesuré	sain	0.728	19.5	SEPSIS ×
FN silencieux	62–86	35.0 –36.6	80–148	0.9–1.3	sepsis	0.013	0.12	non-sepsis ×

Interprétation clinique. Le **FP incertain** illustre l’apport principal du MC Dropout : le modèle prédit à tort SEPSIS (la chute brutale de MAP de 92 à 69 mmHg associée à une tachycardie marquée à 135 bpm évoque une instabilité hémodynamique compatible avec un sepsis), *mais* sa variance (1.95×10^{-2}) est près de **20 fois supérieure** à celle d’un TP confiant. Dans un système de surveillance en USI, cette variance permettrait de classer cette alerte en “à vérifier” plutôt qu’en alarme automatique, économisant une intervention non nécessaire tout en sollicitant le clinicien sur les cas réellement ambigus.

À l’inverse, le **FN silencieux** est plus problématique : le modèle rate le sepsis (probabilité 0.013, sous le seuil 0.018) *et* sa variance reste faible — il ne sait pas qu’il se trompe. Ce cas, caractérisé par une hypothermie atypique (35.0°C , à l’opposé du tableau classique fébrile) et

un MAP large mais variable, correspond à une présentation clinique trompeuse que la base d’entraînement ne contient pas suffisamment. C’est la limite intrinsèque de toute estimation d’incertitude basée uniquement sur la stochasticité interne du modèle (incertitude épistémique) : elle ne capture pas l’incertitude *aléatoire* due aux données rares ou hors distribution.

5.8 Ablation : impact du ratio de labels

TABLE 7 – Performance en fonction du ratio de labels positifs utilisés pour le guidage conditionnel. Le modèle de diffusion est ré-entraîné à chaque ratio.

Ratio	Labels (+)	AUROC↑	AUPRC↑	F1↑	ECE↓
5%	108	0.8642	0.1443	0.1410	0.0170
10%	215	0.8679	0.1363	0.1139	0.0088
25%	539	0.8669	0.1484	0.1153	0.0179
50%	1078	0.8684	0.1356	0.1228	0.0058

6 Analyse et Discussion

6.1 Apport de l’augmentation par diffusion

La comparaison entre le Transformer vanilla (AUROC = 0.789) et notre méthode (AUROC = 0.868) révèle un gain de **+7.9 points d’AUROC** dû exclusivement à l’augmentation par génération conditionnelle. Ce résultat démontre que Diffusion-TS produit des trajectoires patients synthétiques suffisamment réalistes pour entraîner un classifieur robuste avec seulement 215 fenêtres positives labellées.

6.2 Comparaison avec les baselines supervisées

Notre méthode surpasse le BiLSTM de **+2.7 pts AUROC** et de **+25.5 % relatif en AUPRC** (0.1363 vs 0.1086). L’AUPRC est la métrique la plus pertinente pour les datasets déséquilibrés car elle est insensible à l’abondance de vrais négatifs. Le score d’utilité PhysioNet est le plus discriminant : -0.080 pour notre méthode contre -0.165 pour le BiLSTM ($2\times$ meilleur), traduisant un meilleur compromis sensibilité/spécificité au seuil opérationnel.

Le F1 du BiLSTM (0.1252) est légèrement supérieur au nôtre (0.1139) : un modèle entraîné sur données synthétiques a une frontière de décision plus diffuse, ce qui pénalise marginalement le F1 à seuil fixe.

6.3 Qualité de la calibration et incertitude

L’ECE de **0.009** indique une très bonne calibration, propriété essentielle en milieu clinique. La corrélation incertitude–erreur de **0.426** confirme l’utilité du MC Dropout : la variance sur les prédictions incorrectes (au seuil opérationnel de Youden) est **12.8 fois plus élevée** que sur les correctes (6.85×10^{-4} vs 5.34×10^{-5}).

6.4 Robustesse au ratio de labels

Le résultat le plus frappant de l’ablation est la **stabilité remarquable de l’AUROC** à travers tous les ratios : la variation totale n’est que de 0.004 points (0.8642 à 0.8684). Cela s’explique par l’architecture semi-supervisée : le modèle de diffusion apprend la distribution générale des trajectoires patients sur *toutes* les données sans supervision, et le guidage conditionnel

ne sert qu'à orienter la génération synthétique. Avec seulement **108 fenêtres positives labellées (5%)**, le système atteint déjà $\text{AUROC} = 0.864$.

L'AUPRC oscille entre 0.136 et 0.148 sans tendance monotone (5% : 0.144, 10% : 0.136, 25% : 0.148, 50% : 0.136), avec le maximum atteint à 25%. Le F1 culmine quant à lui à 5% (0.141), pas au ratio le plus riche en labels. Cette absence de monotonie est **cohérente avec notre thèse centrale** : si la performance dépendait fortement du nombre de labels, on observerait une croissance régulière entre 5% et 50%. Au lieu de cela, la variation est faible et bruitée, ce qui confirme que la diffusion apprend l'essentiel de sa structure sur les 94 000 fenêtres non labellées, et que le guidage conditionnel n'apporte qu'un effet secondaire.

L'ECE varie aussi de façon non monotone (0.006 à 0.018 selon le ratio) mais reste partout inférieure à 0.02, ce qui demeure cliniquement acceptable. Les fluctuations ECE peuvent provenir de la stochasticité du training (un seul seed par ratio dans notre étude).

6.5 Entraînement et early stopping

L'évolution de l'AUROC de validation a révélé un sur-apprentissage dès l'époch 9 ($\text{AUROC} = 0.8521$ à l'époch 8, puis déclin vers 0.760 à l'époch 50). L'early stopping avec patience = 10 a permis de sauvegarder le meilleur modèle automatiquement. Ce comportement s'explique par la présence de données synthétiques dans le jeu d'entraînement augmenté : le modèle finit par mémoriser leurs patterns plutôt que les patterns cliniques réels.

6.6 Score d'utilité clinique PhysioNet

Le score de -0.080 est très proche de zéro (vs -1.97 avec seuil par défaut de 0.5). Le seuil optimal de 0.0178 reflète le déséquilibre asymétrique de la fonction de coût clinique : pénalité $\text{FN} = -2.0$, pénalité $\text{FP} = -0.05$.

6.7 Limitations

1. **AUPRC modeste (0.136)** : les meilleures solutions du challenge PhysioNet 2019 atteignaient 0.3–0.5 avec accès à l'intégralité des labels.
2. **Diffusion sous-entraînée** : 100 epochs suffisent pour faire converger la loss mais pas pour générer des échantillons optimaux. Un entraînement à 200+ epochs améliorerait la qualité des synthétiques.
3. **Score d'utilité simplifié** : nous utilisons une approximation du score PhysioNet 2019 (TP/FP/FN/TN constants par fenêtre) au lieu de la version officielle par-patient avec décroissance temporelle (`dt_early`, `dt_optimal`, `dt_late`). Les valeurs absolues ne sont donc pas directement comparables aux scores du challenge ; les comparaisons inter-méthodes au sein de ce rapport restent cohérentes car toutes utilisent la même formule.

7 Conclusion

Ce projet démontre la faisabilité de l'adaptation de Diffusion-TS à la prédiction précoce du sepsis dans un cadre semi-supervisé avec incertitude bayésienne. Les trois contributions annoncées en introduction sont validées expérimentalement :

1. **Première application de Diffusion-TS au domaine clinique et à une tâche de classification.** Le modèle, initialement conçu pour la génération de séries temporelles génériques (financières, énergétiques, physiques), est transposé avec succès aux trajectoires d'unité de soins intensifs. Notre pipeline atteint $\text{AUROC} = 0.868$ et $\text{AUPRC} = 0.136$ sur le test set, surpassant cinq baselines dont l'approche signature gagnante du PhysioNet Challenge 2019.

2. **La génération conditionnelle semi-supervisée fonctionne.** En entraînant la diffusion sur l'intégralité du dataset (labellé + non labellé) avec *classifier-free guidance*, on produit des trajectoires synthétiques dont la qualité est validée visuellement et statistiquement (figures 4 et 5). Gain de classification mesuré : **+7.9 pts AUROC** vs Transformer vanilla (preuve directe de l'apport de l'augmentation) et **+2.7 pts** vs BiLSTM supervisé. À protocole identique, la diffusion surpasse également l'approche GAN (0.868 vs 0.836 pour TimeGAN), ce qui justifie le choix architectural fait à la suite de Hirnschall.
3. **La quantification d'incertitude par MC Dropout est exploitable.** La variance des 50 passes stochastiques est **×12.8 plus élevée** sur les prédictions incorrectes que sur les correctes (Pearson $r = 0.43$), avec un ECE de **0.009** qui place le modèle parmi les mieux calibrés de la comparaison. Le cas qualitatif *FP incertain* (table 6) illustre concrètement comment cette incertitude distingue une alerte fiable d'une alerte à vérifier par un clinicien.

Code source, tests (76 tests, 100 % de réussite) et instructions de reproduction : <https://github.com/BigYellowData/diffusion-ts-sepsis>

Références

- [1] Yuan, X. & Qiao, Y. (2024). *Diffusion-TS : Interpretable Diffusion for General Time Series Generation*. ICLR 2024.
- [2] Reyna, M.A. et al. (2020). *Early Prediction of Sepsis from Clinical Data : The PhysioNet/Computing in Cardiology Challenge 2019*. Critical Care Medicine.
- [3] Gal, Y. & Ghahramani, Z. (2016). *Dropout as a Bayesian Approximation : Representing Model Uncertainty in Deep Learning*. ICML 2016.
- [4] Nichol, A. & Dhariwal, P. (2021). *Improved Denoising Diffusion Probabilistic Models*. ICML 2021.
- [5] Hirnschall, D. (2025). *Semi-Supervised Bayesian GANs with Log-Signatures for Uncertainty-Aware Credit Card Fraud Detection*. arXiv.
- [6] Morrill, J. et al. (2020). *Utilization of the Signature Method to Identify the Early Onset of Sepsis from Multivariate Physiological Time Series*. Critical Care Medicine, 48(10).
- [7] Yoon, J., Jarrett, D. & van der Schaar, M. (2019). *Time-series Generative Adversarial Networks*. NeurIPS 2019.